Laporan Ujian Tindak Lanjut Exploratory Data Analysis (EDA)

Mata Kuliah Sains Data

Dosen Pengampu : Dr. Tita Karlita, S.Kom., M.Kom.



Disusun Oleh :

Raihan Ridho (1226800003)

POLITEKNIK ELEKTRONIKA NEGERI SURABAYA

DEPARTEMEN TEKNIK INFORMATIKA DAN KOMPUTER

PROGRAM STUDI PASCASARJANA TEKNIK INFORMATIKA

NOVEMBER 2026

A. Deskripsi Ujian

1.1 Latar Belakang

Exploratory Data Analysis (EDA) merupakan tahap awal analisis data yang bertujuan memahami struktur, distribusi, karakteristik, dan kualitas dataset sebelum dilakukan pemodelan. Melalui EDA, peneliti dapat mengidentifikasi permasalahan data dan menentukan strategi preprocessing berdasarkan temuan empiris.

Pada laporan ini, EDA dilakukan terhadap Indonesian Multi-Source Face Dataset (IMSFD), yang digunakan sebagai data pendukung penelitian pengembangan sistem face matching berbasis deep face recognition untuk verifikasi identitas. Kualitas dataset wajah tidak hanya ditentukan oleh jumlah citra, tetapi juga oleh resolusi, pencahayaan, ketajaman, ukuran wajah, keberhasilan deteksi, dan ketepatan label identitas.

Permasalahan yang perlu diperhatikan meliputi citra hitam atau kosong, resolusi rendah, kegagalan deteksi wajah, ketidakseimbangan jumlah citra antaridentitas, serta kemungkinan duplikasi data. Permasalahan tersebut dapat memengaruhi hasil analisis statistik dan berpotensi menimbulkan evaluasi model yang tidak representatif apabila tidak ditangani dengan tepat.

Oleh karena itu, laporan ini menindaklanjuti temuan EDA melalui persiapan data, perbandingan karakteristik sebelum dan sesudah preprocessing, pengujian hipotesis, analisis sensitivitas, serta pembahasan keterbatasan dataset. Hasil analisis diharapkan menjadi dasar yang lebih terukur untuk mempersiapkan eksperimen face matching pada penelitian selanjutnya.

1.2 Deskripsi Datasets

Dataset yang digunakan dalam penelitian ini adalah Indonesian Multi-Source Face Dataset (IMSFD), yang diperoleh dari berkas IMSFD.zip dengan ukuran sekitar 5,83 GB. Dataset berisi citra wajah berformat PNG dengan kanal warna RGB dan label identitas yang direpresentasikan

melalui struktur folder. Adapun Karakteristik Utama Dataset Dapat Dijelaskan Sebagai Berikut :

Komponen	Keterangan
Sumber Data	Imsfd.Zip
Jenis Data	Citra Wajah Png, Tiga Kanal Warna (Rgb)
Jumlah Citra Awal	26.760 Citra
Jumlah Identitas	68 Identitas
Jumlah Subset	3 Subset: A1, A2, Dan B1
Identitas Pada A1	24 Identitas
Identitas Pada A2	23 Identitas
Identitas Pada B1	21 Identitas
Struktur Penyimpanan	Subset/Split/Identitas/File
Variabel Metadata	22 Kolom Numerik, Kategorik, Dan Boolean
Metode Deteksi Awal	Opencv Dan Haar Cascade
Fokus Analisis Ujian	Metadata Citra Dan Kualitas Deteksi Wajah

Berdasarkan hasil EDA, dataset awal terdiri atas 26.760 citra dan 68 identitas yang terbagi ke dalam tiga subset, yaitu A1, A2, dan B1. Jumlah citra pada subset A1 sebanyak 10.655, A2 sebanyak 8.020, dan B1 sebanyak 8.085. Analisis mencakup pemeriksaan metadata, dimensi citra, ukuran berkas, brightness, contrast, sharpness, rasio area wajah, dan status deteksi wajah menggunakan OpenCV dan Haar Cascade.

Pembagian data awal terdiri atas 21.048 citra pelatihan dan 5.712 citra pengujian, masing-masing sekitar 78,7% dan 21,3%. Seluruh 68 identitas ditemukan pada kedua kelompok tersebut. Oleh karena itu, pembagian awal perlu dievaluasi kembali sebelum digunakan untuk mengukur generalisasi model, khususnya karena terdapat potensi ketergantungan antarcitra dan duplikasi lintas kelompok data.

1.3 Tujuan Ujian

1. Mengidentifikasi Temuan EDA Yang Berpengaruh Terhadap Kualitas Dan Kelayakan Dataset IMSFD.

2. Menentukan Strategi Penanganan Citra Tidak Valid, Resolusi Rendah, Duplikasi, Nilai Ekstrem, Dan Metadata Yang Tidak Tersedia.
3. Membandingkan Karakteristik Data Sebelum Dan Sesudah Preprocessing.
4. Menguji Minimal Dua Hipotesis Yang Berasal Dari Temuan EDA Menggunakan Metode Statistik Yang Sesuai.
5. Mengevaluasi Ketahanan Hasil Analisis Terhadap Perubahan Konfigurasi Preprocessing.
6. Mengidentifikasi Keterbatasan Dataset Dan Merumuskan Implikasi Hasil EDA Terhadap Penelitian Pengembangan Sistem Face Matching.

1.4 Manfaat Ujian

Manfaat yang diharapkan dari pelaksanaan ujian tindak lanjut Exploratory Data Analysis (EDA) ini adalah sebagai berikut.

1. Meningkatkan Pemahaman terhadap Karakteristik Dataset. Memberikan pemahaman yang lebih mendalam mengenai struktur, distribusi, kualitas, dan permasalahan pada Indonesian Multi-Source Face Dataset (IMSFD), khususnya yang berkaitan dengan kualitas citra wajah dan keberhasilan deteksi wajah.
2. Menentukan Strategi Preprocessing yang Tepat. Menjadi dasar dalam menentukan tindakan terhadap citra hitam atau kosong, citra beresolusi rendah, duplikasi, nilai ekstrem, dan metadata yang tidak tersedia sehingga proses pembersihan dataset dapat dilakukan secara terukur dan dapat dipertanggungjawabkan.
3. Meningkatkan Keandalan Analisis Data. Membantu mengidentifikasi potensi bias, ketidakseimbangan jumlah citra antaridentitas, serta kebocoran data (data leakage) yang dapat memengaruhi validitas hasil analisis dan evaluasi model.
4. Memperoleh Bukti Empiris melalui Pengujian Statistik. Memberikan pengalaman dalam menguji hipotesis berdasarkan temuan EDA menggunakan metode statistik yang sesuai dengan karakteristik data, serta menafsirkan hasil pengujian secara objektif.
5. Mengevaluasi Ketahanan Hasil Analisis. Mengetahui sejauh mana kesimpulan analisis dipengaruhi oleh perubahan parameter preprocessing, ambang resolusi, dan penanganan pencilan melalui analisis sensitivitas.
6. Mendukung Pengembangan Penelitian Tesis. Menjadi landasan dalam mempersiapkan dataset untuk penelitian pengembangan sistem face

matching berbasis Deep Face Recognition, terutama pada tahap deteksi wajah, penilaian kualitas citra, ekstraksi face embedding, dan evaluasi verifikasi identitas.

7. Meningkatkan Reproduksibilitas Penelitian. Mendorong penerapan proses analisis yang terdokumentasi, konsisten, dan dapat diulang sehingga hasil EDA dapat diperiksa kembali dan digunakan sebagai dasar bagi eksperimen selanjutnya.

B. Tindak Lanjut Temuan EDA

2.1 Tabel Temuan EDA, Bukti, Keputusan, dan Alasan

Temuan EDA digunakan sebagai dasar untuk menentukan perlakuan terhadap data. Setiap keputusan perlu didukung oleh bukti yang dapat diukur agar proses pembersihan tidak dilakukan secara sembarangan. Berikut ini adalah Tabel Temuan EDA :

No.	Temuan EDA	Bukti	Keputusan	Alasan
1	Terdapat citra hitam atau kosong	Ditemukan 468 citra dengan brightness di bawah 5 dan sharpness bernilai 0. Sebanyak 439 dari 468 citra tersebut berasal dari subset B1.	Mengeluarkan citra hitam atau kosong dari analisis utama.	Citra tersebut tidak menyediakan informasi wajah yang memadai dan dapat menyebabkan kegagalan deteksi serta memengaruhi hasil pengujian statistik.
2	Terdapat citra berukuran sangat kecil	Setelah tahap pembuangan citra hitam, ditemukan 453 citra dengan sisi terpendek kurang dari 64 piksel.	Menggunakan ambang ukuran minimum 64 piksel pada tahap pembersihan utama.	Resolusi yang terlalu kecil membatasi informasi wajah. Proses *upsampling* tidak dapat mengembalikan detail yang memang tidak terdapat pada citra awal.
3	Terdapat dugaan duplikasi citra	Ditemukan 1.244 citra dengan kombinasi metadata	Melakukan deduplikasi setelah citra tidak valid dan citra kecil	Duplikasi dapat membuat hasil evaluasi terlalu optimistis karena citra yang sama

		identik dan 1.236 pasangan duplikasi lintas data pelatihan dan pengujian pada pemeriksaan awal.	dikeluarkan, kemudian memeriksa kembali duplikasi lintas split.	dapat muncul pada data pelatihan dan pengujian.
4	Identitas terdapat pada kedua split awal	Seluruh 68 identitas ditemukan pada data pelatihan maupun pengujian.	Membuat pembagian ulang berdasarkan identitas menggunakan kolom split_v2.	Untuk pengujian generalisasi open-set, identitas pengujian harus tidak terlihat selama pelatihan atau pemilihan model.
5	Jumlah citra per identitas tidak seimbang	Jumlah citra per identitas berkisar 27–640, dengan koefisien variasi sekitar 0,31. Terdapat dua identitas dengan kurang dari 100 citra.	Membuat penanda keseimbangan jumlah citra dengan batas 300 citra per identitas pada analisis yang memerlukannya, tanpa langsung membuang identitas minoritas.	Ketidakseimbangan dapat menyebabkan identitas yang memiliki banyak citra mendominasi analisis. Pengendalian diperlukan tanpa menghilangkan keragaman identitas secara berlebihan.
6	Distribusi beberapa variabel sangat miring	Skewness sharpness sekitar 12,8 dan ukuran file sekitar 3,9.	Menggunakan transformasi logaritmik log(1+x) untuk analisis variabel yang sesuai. Outlier yang masih valid tidak otomatis dihapus.	Transformasi log membantu mengurangi kemencengan distribusi. Nilai ekstrem dapat mencerminkan kondisi pengambilan citra yang sah sehingga harus dibedakan dari kesalahan data.
7	Sebagian citra tidak berhasil dideteksi wajahnya	Pada data awal, 24.107 citra terdeteksi wajahnya dari 26.760	Tidak mengimputasi bounding box yang hilang. Menambahkan indikator	Kegagalan deteksi merupakan *missingness* yang bersifat struktural untuk fitur wajah. Mengisi bounding

		citra, sedangkan 2.653 citra tidak terdeteksi. Median sharpness citra yang tidak terdeteksi sebesar 10,6, dibandingkan dengan 48,1 untuk citra terdeteksi.	face_detected dan melakukan pemeriksaan kualitas deteksi.	box secara otomatis tanpa informasi yang memadai berisiko menghasilkan data yang tidak sesuai kenyataan.
8	Rasio lebar dan tinggi citra bervariasi	Sekitar 92,5% citra memiliki rasio yang mendekati persegi, terdapat 1.492 citra landscape, dan 409 citra dengan rasio tinggi yang ekstrem.	Menerapkan deteksi, alignment, crop, dan resize dengan mempertahankan proporsi wajah.	Peregangan citra secara langsung dapat mendistorsi bentuk wajah dan memengaruhi representasi embedding.
9	Kualitas citra berbeda antar-subset	Pada EDA awal, tingkat deteksi A2 sekitar 96,6%, sedangkan B1 sekitar 83,5%. Setelah pembersihan, tingkat deteksi A1, A2, dan B1 masing-masing sekitar 91,6%, 96,5%, dan 89,2%.	Mempertahankan informasi subset sebagai variabel analisis dan mengevaluasi kualitas secara terpisah antar-subset.	Perbedaan kualitas dapat menyebabkan perbedaan tingkat keberhasilan deteksi yang tidak semata-mata berhubungan dengan identitas.
10	Hubungan lebar citra dengan rasio area wajah terlalu kuat pada EDA awal	Korelasi awal dilaporkan sebesar Pearson r = -0,85. Setelah pemeriksaan ulang pada	Menggunakan korelasi Spearman sebagai analisis utama untuk hubungan tersebut.	Distribusi multimodal, pencilan, dan perbedaan resolusi dapat memengaruhi Pearson. Spearman

		data bersih, korelasi Spearman menjadi sekitar -0,50.		lebih sesuai untuk mengevaluasi hubungan monoton pada data yang tidak harus berdistribusi normal.

Berdasarkan tabel tersebut, terdapat tiga keputusan yang paling penting yaitu :

1. Pertama, citra tidak valid harus dipisahkan dari citra yang hanya memiliki kualitas rendah. Citra hitam dengan brightness yang sangat rendah tidak memiliki informasi visual yang memadai, sedangkan citra beresolusi rendah belum tentu sepenuhnya tidak berguna. Oleh karena itu, keputusan penghapusan perlu didasarkan pada kriteria yang jelas dan diuji melalui analisis sensitivitas.
2. Kedua, duplikasi dan pembagian data menjadi perhatian utama dalam validitas evaluasi. Dataset yang memiliki banyak citra tidak otomatis menghasilkan evaluasi yang baik apabila citra yang saling identik tersebar di antara data pelatihan dan pengujian.
3. Ketiga, kegagalan deteksi wajah tidak dapat langsung diartikan sebagai tidak adanya wajah di dalam citra. Haar Cascade memiliki keterbatasan dalam mendeteksi wajah pada kondisi pose, pencahayaan, atau resolusi tertentu. Dengan demikian, variabel face_detected dalam penelitian ini sebaiknya ditafsirkan sebagai hasil deteksi algoritma, bukan sebagai label kebenaran mutlak bahwa wajah terdapat atau tidak terdapat pada citra.

2.2 Tanggapan Terhadap Temuan EDA (Sebelumnya)

Setelah melakukan analisis lanjutan, terdapat beberapa temuan EDA yang perlu dikoreksi atau diberi interpretasi, berikut ini penjelasannya :

1. Koreksi Statistik Deskriptif

   Pada presentasi EDA awal, terdapat beberapa angka yang perlu diperbaiki :

- Nilai brightness yang tertulis 1.080 seharusnya 108,0.
- Skewness lebar citra yang tertulis 283 seharusnya 2,83.
- Jumlah citra yang tidak terdeteksi wajahnya seharusnya 2.653, bukan 2.623, karena 26.760 dikurangi 24.107 sama dengan 2.653.
- Proporsi pembagian data awal yang sebenarnya adalah 78,7% data pelatihan dan 21,3% data pengujian, bukan tepat 80% dan 20%.

2. Klaim Mengenai Kesamaan Ukuran Wajah Pada Data Pelatihan Dan Pengujian Perlu Dibatasi.

   EDA awal menunjukkan bahwa median rasio area wajah pada data pelatihan dan pengujian relatif sama, yaitu sekitar 0,71. Temuan ini hanya menunjukkan tidak adanya pergeseran yang berarti pada median variabel tersebut. Temuan ini tidak membuktikan bahwa kedua kelompok data independen atau bebas dari kebocoran data.

   Pemeriksaan lanjutan justru mengidentifikasi duplikasi citra lintas split. Oleh sebab itu, pembagian data harus ditinjau ulang sebelum digunakan untuk mengevaluasi model face matching.

3. Jumlah Citra Yang Besar Tidak Identik Dengan Jumlah Sampel Independen Yang Besar.

   Sebanyak 26.760 citra berasal dari 68 identitas. Citra-citra dari identitas yang sama dapat memiliki karakteristik wajah dan kondisi pengambilan yang saling berkaitan. Analisis yang menganggap seluruh citra sebagai observasi independen berisiko menghasilkan interval kepercayaan yang terlalu sempit.

4. Dugaan Frame Berurutan Perlu Dibuktikan Pada Citra Asli.

Kombinasi metadata identik merupakan indikasi adanya duplikasi, tetapi belum cukup untuk memastikan seluruh hubungan antar-citra. Pemeriksaan lanjutan menggunakan cryptographic hash, perceptual hash, atau jarak embedding dapat membantu membedakan duplikasi piksel yang persis sama dari citra yang sangat mirip tetapi tidak identik. Dengan demikian, tindak lanjut EDA tidak hanya memperbaiki kualitas data, tetapi juga memperbaiki interpretasi terhadap hasil analisis sebelumnya.

C. Persiapan Datasets

3.1 Strategi Persiapan Dataset

Persiapan dataset dilakukan berdasarkan temuan Exploratory Data Analysis (EDA) terhadap Indonesian Multi-Source Face Dataset (IMSFD). Tahap ini bertujuan memastikan bahwa data yang digunakan dalam penelitian memiliki struktur, metadata, dan kualitas yang memadai untuk mendukung analisis serta pengembangan sistem face matching.

Berdasarkan notebook EDA, dataset awal terdiri atas 26.760 citra dari 68 identitas yang terbagi ke dalam tiga subset, yaitu A1, A2, dan B1. Analisis awal telah mencakup pemeriksaan struktur folder, dimensi citra, ukuran file, brightness, contrast, sharpness, rasio area wajah, dan hasil deteksi wajah menggunakan OpenCV dan Haar Cascade. Strategi persiapan dataset dirancang melalui pemeriksaan metadata, identifikasi citra tidak valid, evaluasi resolusi, pemeriksaan duplikasi, penanganan nilai ekstrem, pemeriksaan kegagalan deteksi, serta perancangan pembagian data yang sesuai dengan tujuan evaluasi.

3.2 Tahapan Preprocessing

3.2.1 Pemeriksaan Metadata

Pemeriksaan metadata dilakukan untuk memastikan bahwa setiap citra memiliki informasi yang diperlukan dalam analisis.

Informasi yang diperiksa meliputi identitas, subset, split, nama berkas, dimensi citra, ukuran file, brightness, contrast, sharpness, rasio aspek, dan status deteksi wajah. Hasil EDA menunjukkan bahwa median lebar dan tinggi citra masing-masing sebesar 410 piksel. Median ukuran file sebesar 172,32 KB. Nilai-nilai tersebut menunjukkan bahwa karakteristik citra tidak seragam sehingga diperlukan pemeriksaan kualitas sebelum pemodelan. Hasil pemeriksaan menunjukkan bahwa dimensi dan ukuran berkas citra memiliki variasi yang cukup besar. Oleh karena itu, metadata perlu diperiksa sebelum analisis lanjutan dilakukan. Pemeriksaan ini juga digunakan untuk mengidentifikasi nilai yang tidak tersedia, dimensi yang tidak wajar, dan ketidakkonsistenan informasi citra. Nilai ekstrem tidak langsung dihapus, tetapi terlebih dahulu dievaluasi untuk membedakan kesalahan data dari variasi yang masih valid.

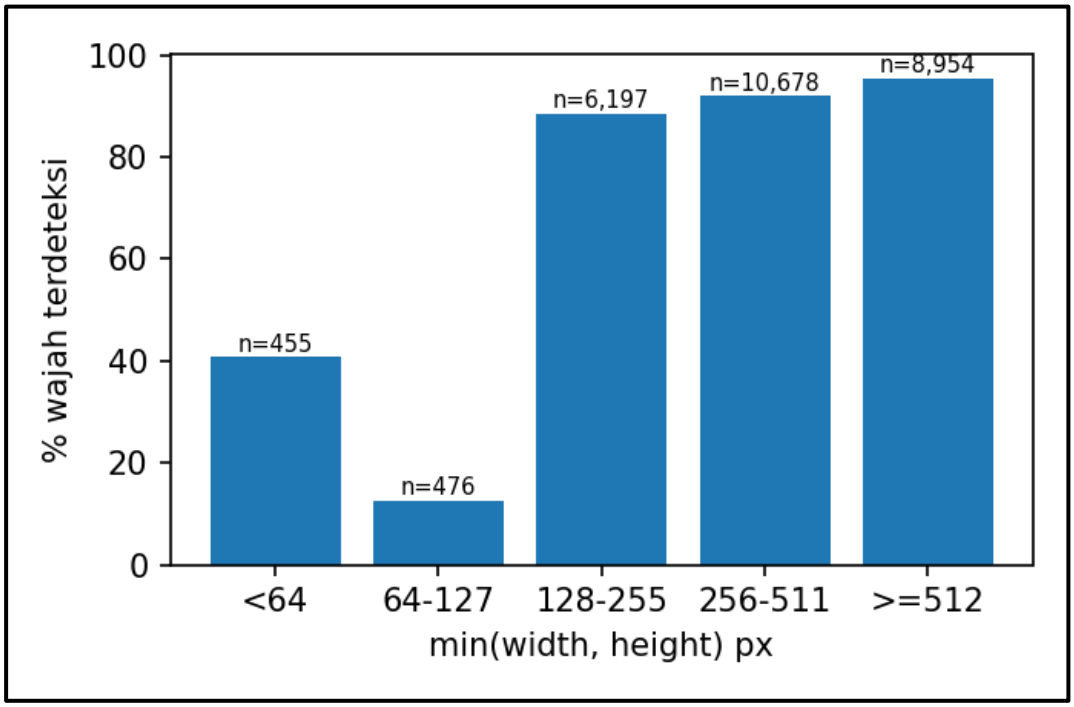
3.2.2 Identifikasi Citra Tidak Valid

Berdasarkan hasil EDA, menunjukkan adanya 468 citra dengan brightness sangat rendah yang diidentifikasi sebagai kandidat citra hitam atau kosong. Temuan tersebut digunakan sebagai dasar pemeriksaan lebih lanjut. Sebelum citra dihapus secara permanen, perlu dilakukan pemeriksaan terhadap nilai brightness, sharpness, dan tampilan citra asli. Kriteria brightness di bawah 5 dan sharpness sebesar 0 harus diperlakukan sebagai aturan penyaringan yang perlu divalidasi, bukan sebagai bukti mutlak bahwa suatu citra tidak memiliki informasi visual. Citra yang telah dipastikan tidak valid dapat dikeluarkan dari analisis utama. Citra yang hanya gelap tetapi masih memiliki informasi wajah sebaiknya dipertahankan untuk evaluasi sensitivitas.

3.2.3 Evaluasi Resolusi Citra

Hasil Exploratory Data Analysis (EDA) menunjukkan bahwa median lebar dan tinggi citra pada dataset IMSFD masing-masing

sebesar 410 piksel. Namun, dimensi citra memiliki variasi yang cukup besar, dengan lebar minimum 1 piksel, tinggi minimum 25 piksel, lebar maksimum 4.176 piksel, dan tinggi maksimum 2.784 piksel. Variasi tersebut menunjukkan bahwa dataset terdiri atas citra dengan resolusi yang berbeda-beda, sehingga perlu dilakukan evaluasi untuk mengetahui hubungan antara ukuran citra dan keberhasilan deteksi wajah



Gambar 3. 1 Tingkat Keberhasilan Deteksi Wajah Berdasarkan Kategori Resolusi Citra.

Berdasarkan Gambar 3.1, tingkat keberhasilan deteksi wajah berbeda pada setiap kategori resolusi yang ditentukan berdasarkan sisi terpendek citra, yaitu nilai minimum antara lebar dan tinggi. Pada kategori sisi terpendek kurang dari 64 piksel, tingkat deteksi sekitar 41% dengan jumlah observasi sebanyak 455 citra. Pada kategori 64–127 piksel, tingkat deteksi sekitar 12% dari 476 citra.

Pada kategori 128–255 piksel, tingkat deteksi mencapai sekitar 88% dari 6.197 citra. Kategori 256–511 piksel menunjukkan tingkat deteksi sekitar 92% dari 10.678 citra, sedangkan kategori dengan sisi terpendek minimal 512 piksel menunjukkan tingkat deteksi sekitar 95% dari 8.954 citra. Secara

deskriptif, kategori citra dengan sisi terpendek 64–127 piksel memiliki tingkat deteksi terendah, sedangkan kategori dengan sisi terpendek minimal 512 piksel memiliki tingkat deteksi tertinggi. Namun, kategori di bawah 64 piksel masih menunjukkan sebagian citra yang berhasil dideteksi. Dengan demikian, resolusi rendah tidak dapat dijadikan satu-satunya dasar untuk menghapus citra.

Ambang sisi terpendek 64 piksel dapat digunakan sebagai konfigurasi awal dalam eksperimen pembersihan, tetapi belum dapat dinyatakan sebagai ambang optimal. Perbandingan ambang 32, 64, dan 128 piksel diperlukan untuk mengetahui perubahan jumlah citra yang dipertahankan dan karakteristik hasil deteksi pada setiap konfigurasi. Grafik ini menunjukkan hubungan deskriptif, bukan bukti hubungan sebab-akibat atau signifikansi statistik.

3.2.4 Pemeriksaan Duplikasi

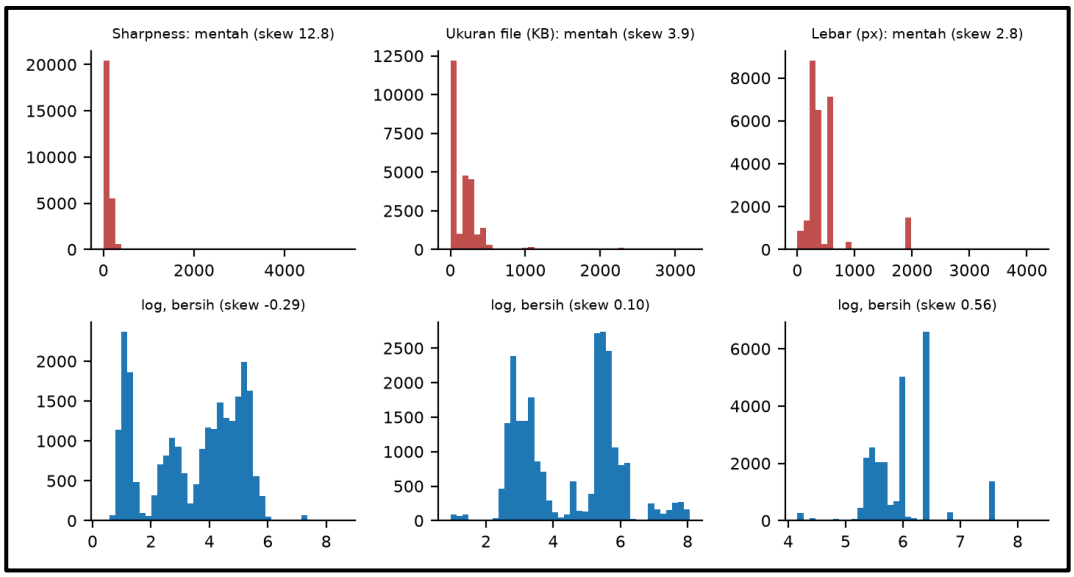
Pemeriksaan duplikasi bertujuan mengidentifikasi citra yang sama atau sangat mirip, khususnya apabila citra tersebut ditemukan pada data pelatihan dan pengujian. Pemeriksaan dapat dilakukan secara bertahap menggunakan hash kriptografis untuk mendeteksi file identik, perceptual hash untuk mengidentifikasi citra yang mirip, serta pemeriksaan visual untuk meninjau kandidat duplikasi. Kombinasi metadata identik tidak cukup untuk memastikan bahwa dua citra merupakan duplikat. Oleh karena itu, jumlah duplikasi perlu ditentukan berdasarkan hasil pemeriksaan file atau citra yang sebenarnya. Setelah duplikasi terverifikasi, citra yang berulang dapat ditangani dengan mempertimbangkan identitas, asal citra, dan tujuan evaluasi.

3.2.5 Transformasi Variabel

Variabel sharpness dan ukuran file memiliki distribusi yang sangat miring ke kanan. Oleh sebab itu, transformasi logaritmik digunakan pada analisis variabel yang sesuai dengan rumus :

$$x = Log\ (1 + x).$$

Transformasi logaritmik menggunakan rumus ln(1 + x) diterapkan pada variabel nonnegatif yang memiliki distribusi menceng ke kanan, seperti sharpness dan ukuran file. Transformasi ini bertujuan mengurangi pengaruh nilai ekstrem terhadap tampilan distribusi dan analisis lanjutan. Namun, transformasi logaritmik tidak menjamin bahwa distribusi menjadi normal dan tidak menghilangkan kebutuhan untuk memeriksa nilai yang tidak valid.



Gambar 3. 2 Perbandingan distribusi variabel sharpness, ukuran file, dan lebar citra sebelum dan sesudah transformasi logaritmik

Berdasarkan Gambar 3.1, distribusi data mentah menunjukkan kemencengan ke kanan, terutama pada variabel sharpness, ukuran file, dan lebar citra. Nilai skewness yang tercantum pada grafik masing-masing sekitar 12,8; 3,9; dan 2,8. Setelah transformasi logaritmik, nilai skewness berubah menjadi sekitar −0,29; 0,10; dan 0,56. Hal ini menunjukkan bahwa kemencengan distribusi berkurang, terutama pada sharpness dan ukuran file.

Meskipun demikian, transformasi logaritmik tidak menjamin distribusi menjadi normal. Bentuk distribusi setelah transformasi masih perlu diperiksa, khususnya apabila analisis selanjutnya mensyaratkan asumsi tertentu.

3.2.6 Penanganan Kegagalan Deteksi

Pada dataset awal, sebanyak 24.107 citra berhasil dideteksi wajahnya dan 2.653 citra tidak berhasil dideteksi. Kegagalan deteksi tidak langsung diartikan sebagai tidak adanya wajah pada citra. Kegagalan tersebut dapat dipengaruhi oleh resolusi, pencahayaan, pose, oklusi, maupun keterbatasan algoritma Haar Cascade. Oleh karena itu, informasi kegagalan deteksi dipertahankan sebagai indikator **`face_detected`.** Bounding box yang tidak tersedia tidak diisi secara otomatis karena nilai tersebut harus berasal dari hasil deteksi yang valid.

3.3 Hasil Pembersihan Dataset

Hasil pembersihan utama dataset Indonesian Multi-Source Face Dataset (IMSFD) dirangkum berdasarkan tiga tahapan, yaitu penghapusan citra hitam, penyaringan citra berdasarkan ukuran sisi terpendek, dan deduplikasi. Tahapan tersebut bertujuan mengurangi citra yang tidak layak digunakan serta menghindari pengulangan data dalam analisis selanjutnya.

Tabel 3. 1 Ringkasan Hasil Pembersihan Dataset IMSFD

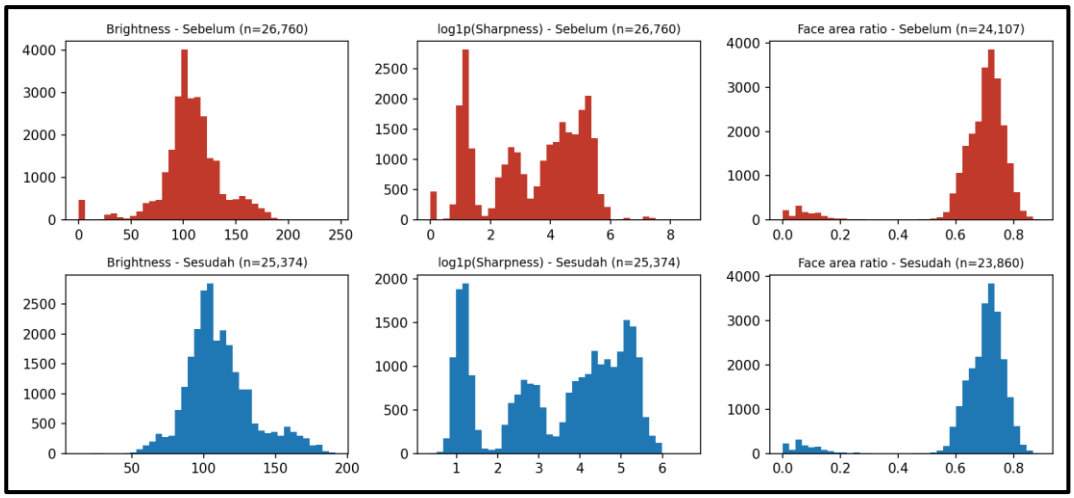
Tahapan	Citra Dikeluarkan	Sisa Citra
Dataset awal	–	26.760
Penghapusan citra hitam	468	26.292
Penyaringan sisi terpendek kurang dari 64 piksel	453	25.839
Deduplikasi	1.231	24.608

Berdasarkan Tabel 3.1, proses pembersihan utama menghasilkan 24.608 citra dari 26.760 citra awal. Jumlah tersebut merupakan hasil penghapusan

citra hitam, penyaringan berdasarkan resolusi, dan deduplikasi sesuai konfigurasi yang digunakan. Perbandingan distribusi variabel sebelum dan sesudah preprocessing dilakukan untuk mengevaluasi perubahan karakteristik data yang dipertahankan.

Jumlah observasi pada setiap histogram perlu disesuaikan dengan tahap preprocessing dan ketersediaan nilai variabel yang digunakan. Dengan demikian, perubahan distribusi dapat diinterpretasikan berdasarkan data yang benar-benar dianalisis. Perubahan histogram tidak dengan sendirinya membuktikan bahwa kualitas citra meningkat, melainkan menunjukkan perubahan komposisi data setelah proses pembersihan.

Secara keseluruhan, sebanyak 2.152 citra dikeluarkan dari dataset awal, atau sekitar 8,05% dari keseluruhan data. Dengan demikian, sekitar 91,95% citra awal dipertahankan untuk analisis selanjutnya. Hasil ini menunjukkan bahwa proses pembersihan mengurangi jumlah data secara terbatas dengan menerapkan kriteria kualitas dan duplikasi yang telah ditentukan.



Gambar 3. 3 Perbandingan Distribusi Brightness, Logaritma Sharpness, Dan Rasio Area Wajah Sebelum Dan Sesudah Preprocessing Dataset IMSFD.

Berdasarkan Gambar 3.2, histogram brightness sebelum preprocessing menunjukkan bahwa sebagian besar citra memiliki intensitas kecerahan pada rentang sekitar 90–130, dengan konsentrasi tertinggi di sekitar nilai

100–110. Selain itu, terdapat sejumlah citra dengan brightness sangat rendah dan sebagian citra dengan nilai kecerahan yang lebih tinggi. Setelah preprocessing, distribusi brightness masih terkonsentrasi di sekitar rentang 90–130, tetapi bentuk dan frekuensi distribusinya mengalami perubahan. Hal ini menunjukkan bahwa komposisi citra berdasarkan tingkat kecerahan berubah setelah proses pembersihan dilakukan.

Pada histogram logaritma sharpness, distribusi sebelum preprocessing memperlihatkan beberapa kelompok nilai, terutama pada rentang sekitar 1–1,5, 2,5–3, dan 4–5,5. Setelah preprocessing, distribusi masih menunjukkan pola beberapa kelompok nilai, dengan konsentrasi yang cukup tinggi pada rentang sekitar 1 dan 4–5,5. Dengan demikian, variasi ketajaman masih ditemukan pada citra yang dipertahankan. Perubahan distribusi tersebut mengindikasikan adanya perubahan komposisi data, tetapi belum cukup untuk menyimpulkan bahwa ketajaman citra secara keseluruhan meningkat. Sementara itu, histogram rasio area wajah sebelum preprocessing menunjukkan bahwa sebagian besar nilai terkonsentrasi pada rentang sekitar 0,65–0,80, dengan puncak distribusi di sekitar 0,70–0,75. Terdapat pula sejumlah kecil citra dengan rasio area wajah yang rendah. Setelah preprocessing, distribusi tetap terkonsentrasi pada rentang sekitar 0,65–0,80. Namun, jumlah observasi yang digunakan berkurang dari 24.107 menjadi 23.860. Hal ini menunjukkan bahwa terdapat perbedaan jumlah citra dengan nilai rasio area wajah yang tersedia pada kedua kondisi.

Secara keseluruhan, Gambar 3.2 memperlihatkan bahwa preprocessing diikuti oleh perubahan distribusi brightness dan logaritma sharpness, sedangkan distribusi rasio area wajah tetap terkonsentrasi pada rentang yang relatif serupa. Perubahan tersebut perlu diinterpretasikan sebagai perubahan karakteristik data yang dipertahankan, bukan sebagai bukti langsung bahwa kualitas seluruh citra meningkat. Untuk memastikan penyebab perubahan distribusi, hasil histogram perlu dibandingkan

dengan tahapan pembersihan dan jumlah observasi valid pada setiap variabel.

3.4 Pembagian Dataset Untuk Analisis Lanjutan

Pembagian awal terdiri atas 21.048 citra pelatihan dan 5.712 citra pengujian. Seluruh 68 identitas terdapat pada kedua split awal. Kondisi tersebut harus dipertimbangkan ketika menentukan tujuan evaluasi. Untuk pengujian generalisasi open-set, identitas pada data pengujian harus terpisah dari identitas yang digunakan selama pelatihan. Sebaliknya, untuk verifikasi 1:1 pada identitas terdaftar, diperlukan pasangan genuine dan impostor yang dirancang secara terpisah. Pemeriksaan duplikasi lintas split juga perlu dilakukan agar hasil evaluasi tidak dipengaruhi oleh kemunculan citra identik pada data pelatihan dan pengujian.

3.5 Kesimpulan Persiapan Dataset

EDA awal telah memberikan gambaran mengenai variasi resolusi, kualitas citra, dan keberhasilan deteksi wajah pada dataset IMSFD. Namun, hasil EDA belum sama dengan hasil preprocessing final. Oleh karena itu, dataset perlu menjalani pembersihan yang terdokumentasi, pemeriksaan duplikasi, deteksi dan alignment wajah, cropping, resizing, serta pembagian data sesuai tujuan evaluasi sebelum digunakan untuk ekstraksi embedding dan face matching.

D. Analisis Lanjutan

4.1 Metode Analisis

Analisis lanjutan dilakukan untuk menguji temuan EDA mengenai hubungan sharpness dengan keberhasilan deteksi wajah, perbedaan tingkat deteksi antar-subset, serta hubungan lebar citra dengan rasio area wajah.

Pengujian meliputi tiga hipotesis. Mann–Whitney U dan Cliff's delta digunakan untuk membandingkan distribusi sharpness antara kelompok

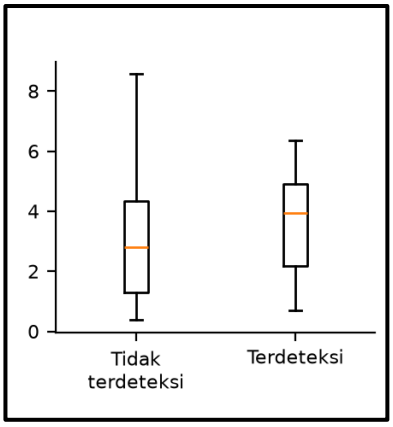
citra yang berhasil dan tidak berhasil dideteksi. Hubungan antara subset dan status deteksi dievaluasi menggunakan tabel kontingensi dan ukuran asosiasi Cramér's V. Sementara itu, hubungan monoton antara lebar citra dan rasio area wajah dianalisis menggunakan korelasi Spearman.

Taraf signifikansi ditetapkan sebesar 0,05. Hasil pengujian perlu dilaporkan melalui statistik uji, nilai p, ukuran efek, dan interval kepercayaan apabila dihitung. Karena beberapa citra berasal dari identitas yang sama, ketergantungan antarcitra perlu dipertimbangkan ketika menghitung ketidakpastian hasil. Seluruh interpretasi didasarkan pada keluaran program yang dapat diverifikasi. Apabila hasil pengujian belum tersedia, kesimpulan mengenai signifikansi statistik tidak ditetapkan terlebih dahulu.

4.2 Hipotesis 1 : Hubungan Sharpness dengan Keberhasilan Deteksi

a) Rumusan Hipotesis
   - H0: Tidak terdapat perbedaan distribusi sharpness antara citra yang berhasil dideteksi wajahnya dan citra yang tidak berhasil dideteksi.
   - H1: Citra yang berhasil dideteksi wajahnya cenderung memiliki sharpness lebih tinggi dibandingkan citra yang tidak berhasil dideteksi.

b) Metode Pengujian
   - Uji Mann–Whitney U dapat digunakan untuk membandingkan distribusi sharpness pada kedua kelompok karena variabel tersebut memiliki distribusi yang miring.
   - Ukuran efek dan interval kepercayaan perlu dilaporkan untuk menunjukkan besarnya perbedaan, bukan hanya nilai signifikansinya. Apabila analisis dilakukan pada tingkat citra, pengelompokan berdasarkan identitas perlu diperhitungkan.



Gambar 4. 1 Perbandingan distribusi log(1 + sharpness) antara citra yang berhasil dideteksi dan citra yang tidak berhasil dideteksi menggunakan Haar Cascade.

Berdasarkan Gambar 4.1, kelompok citra yang berhasil dideteksi menunjukkan median log(1 + sharpness) yang lebih tinggi dibandingkan kelompok citra yang tidak berhasil dideteksi. Secara deskriptif, temuan ini mengindikasikan bahwa ketajaman citra berkaitan dengan keberhasilan deteksi wajah menggunakan Haar Cascade. Namun, perbedaan median pada boxplot saja belum cukup untuk menyimpulkan signifikansi statistik. Oleh karena itu, hasil visualisasi perlu dilengkapi dengan uji Mann–Whitney U, nilai p, ukuran efek Cliff's delta, dan interval kepercayaan jika tersedia.

c) Interpretasi
   - Notebook menunjukkan bahwa median sharpness keseluruhan adalah 42,90 dan terdapat 2.653 citra yang tidak berhasil dideteksi. Namun, keluaran notebook yang tersedia belum menampilkan hasil perbandingan statistik sharpness antara kedua kelompok.
   - Oleh karena itu, keputusan menerima atau menolak H0 belum dapat ditentukan. Pengujian perlu dijalankan pada data yang sama dengan definisi deteksi dan kriteria preprocessing yang konsisten.

Secara deskriptif, hasil EDA menunjukkan bahwa median sharpness pada citra yang berhasil dideteksi lebih tinggi dibandingkan citra yang

tidak berhasil dideteksi. Temuan ini memberikan indikasi bahwa ketajaman citra berkaitan dengan keberhasilan deteksi wajah menggunakan Haar Cascade. Untuk menguji perbedaan tersebut, digunakan uji Mann–Whitney U karena distribusi sharpness menunjukkan kemencengan. Cliff's delta digunakan sebagai ukuran efek untuk menilai besarnya perbedaan antara kedua kelompok.

Namun, perbedaan median pada visualisasi belum cukup untuk menyatakan bahwa hipotesis alternatif didukung secara statistik. Kesimpulan akhir perlu didasarkan pada hasil uji Mann–Whitney U, nilai p, ukuran efek, dan interval kepercayaan apabila tersedia. Ketergantungan antarcitra dari identitas yang sama juga perlu dipertimbangkan dalam penghitungan ketidakpastian.

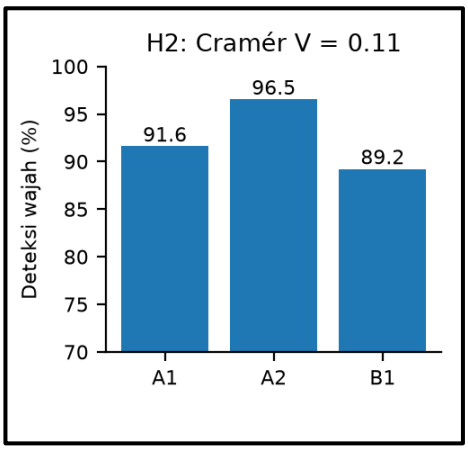
Dengan demikian, hasil deskriptif mendukung perlunya analisis lebih lanjut mengenai hubungan sharpness dan keberhasilan deteksi. Kesimpulan mengenai signifikansi statistik harus ditetapkan setelah pengujian aktual dilakukan.

4.3 Hipotesis 2 : Perbedaan Tingkat Deteksi Antar-Subset

a) Rumusan Hipotesis
   - H0: Tingkat deteksi wajah pada subset A1, A2, dan B1 tidak berbeda secara statistik.
   - H1: Setidaknya terdapat satu subset yang memiliki tingkat deteksi wajah berbeda.

b) Metode Pengujian
   - Analisis dimulai dengan menghitung jumlah citra yang berhasil dan tidak berhasil dideteksi pada setiap subset. Tingkat deteksi dihitung menggunakan jumlah citra terdeteksi dibagi jumlah citra yang dianalisis pada subset tersebut.

- Uji chi-square dapat dipertimbangkan untuk tabel kontingensi subset dan status deteksi apabila asumsi yang diperlukan terpenuhi. Karena citra dapat berkelompok berdasarkan identitas, analisis tambahan pada tingkat identitas atau metode yang memperhitungkan pengelompokan diperlukan untuk menghindari kesimpulan yang terlalu kuat.



Gambar 4. 2 Perbandingan tingkat keberhasilan deteksi wajah pada subset A1, A2, dan B1 serta ukuran asosiasi Cramér's V.

Berdasarkan Gambar 4.2, tingkat keberhasilan deteksi wajah tercatat sebesar 91,6% pada subset A1, 96,5% pada subset A2, dan 89,2% pada subset B1. Secara deskriptif, A2 memiliki tingkat deteksi tertinggi, sedangkan B1 memiliki tingkat deteksi terendah.

Nilai Cramér's V sebesar 0,11 pada grafik menunjukkan besarnya asosiasi antara subset dan status deteksi berdasarkan perhitungan yang digunakan. Nilai ini merupakan ukuran efek dan bukan nilai p, sehingga tidak dapat digunakan sendiri untuk menentukan signifikansi statistik. Untuk menguji hipotesis, diperlukan tabel jumlah citra yang berhasil dan tidak berhasil dideteksi pada setiap subset serta hasil pengujian statistik yang sesuai. Uji chi-square dapat digunakan apabila asumsi yang diperlukan terpenuhi. Karena citra dikelompokkan berdasarkan identitas, ketergantungan antarcitra juga perlu dipertimbangkan.Dengan demikian, hasil deskriptif menunjukkan adanya perbedaan tingkat deteksi antar-subset. Namun, kesimpulan mengenai signifikansi statistik perlu menunggu hasil pengujian aktual dan pemeriksaan asumsi yang sesuai.

c) Interpretasi

- EDA awal mencatat bahwa jumlah citra pada A1, A2, dan B1 masing-masing adalah 10.655, 8.020, dan 8.085. Hasil tersebut menunjukkan bahwa jumlah citra antar-subset tidak sama.
- Namun, perbedaan jumlah citra tidak dengan sendirinya membuktikan perbedaan tingkat deteksi. Kesimpulan mengenai hipotesis ini baru dapat dibuat setelah menghitung tingkat deteksi per subset dan menjalankan pengujian statistik.

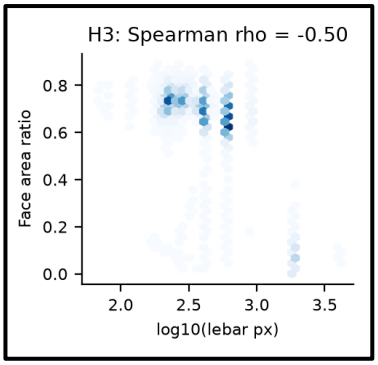
4.4 Hipotesis 3 : Hubungan Lebar Citra dengan Rasio Area Wajah

a) Rumusan Hipotesis

- H0: Tidak terdapat hubungan monoton antara lebar citra dan rasio area wajah.
- H1: Terdapat hubungan negatif antara lebar citra dan rasio area wajah.

b) Metode Pengujian

- Korelasi Spearman digunakan untuk mengukur hubungan monoton antara lebar citra dan rasio area wajah. Metode ini sesuai untuk analisis awal ketika distribusi variabel tidak normal atau mengandung pencilan.
- Analisis perlu menggunakan definisi rasio area wajah yang konsisten dan hanya menyertakan citra dengan hasil deteksi valid. Interval kepercayaan dapat dihitung menggunakan bootstrap yang memperhitungkan pengelompokan identitas.



Gambar 4. 3 Hubungan antara logaritma lebar citra dan rasio area wajah berdasarkan korelasi peringkat Spearman.

Berdasarkan Gambar 4.3, koefisien korelasi Spearman sebesar −0,50 menunjukkan hubungan monoton negatif antara lebar citra dan rasio area wajah pada data yang dianalisis. Artinya, lebar citra yang lebih besar cenderung berkaitan dengan rasio area wajah yang lebih rendah dalam dataset tersebut. Hubungan ini tidak membuktikan bahwa peningkatan lebar citra menyebabkan penurunan rasio area wajah. Pola yang diamati dapat dipengaruhi oleh jarak pengambilan gambar, ukuran wajah di dalam citra, serta variasi sumber data.

Untuk memperkuat kesimpulan, jumlah observasi valid, nilai p, dan interval kepercayaan apabila dihitung perlu dilaporkan. Definisi rasio area wajah juga harus konsisten pada seluruh subset dan skenario preprocessing. Dengan demikian, korelasi Spearman dapat digunakan untuk menggambarkan arah dan kekuatan hubungan monoton antara kedua variabel. Kesimpulan akhir mengenai signifikansi hubungan harus mengikuti hasil pengujian aktual.

c) Interpretasi

- Pada citra yang berhasil dideteksi, median rasio area wajah tercatat sebesar 0,7094. Lebar citra memiliki median 410 piksel dan menunjukkan variasi yang besar.
- Temuan deskriptif tersebut menunjukkan bahwa resolusi citra dan proporsi area wajah perlu dianalisis secara terpisah. Namun, nilai korelasi dan signifikansi hipotesis belum dapat dinyatakan sebagai hasil final sebelum dihitung ulang menggunakan data aktual.

4.5 Analisis Pendukung : Regresi Logistik

Regresi logistik dapat digunakan sebagai analisis pendukung untuk mengevaluasi hubungan karakteristik citra dengan status keberhasilan deteksi wajah. Variabel dependen adalah face_detected, sedangkan variabel independen dapat mencakup sharpness, brightness, contrast, dimensi citra, dan subset. Apabila model dijalankan, hasilnya perlu dilaporkan melalui koefisien regresi, odds ratio, interval kepercayaan, dan

nilai p. Kemampuan prediksi juga perlu dievaluasi menggunakan skema validasi yang sesuai dan tidak mengalami kebocoran data.

Karena citra dari identitas yang sama dapat saling berkaitan, pembagian data dan penghitungan ketidakpastian perlu mempertimbangkan pengelompokan identitas. Analisis ini hanya mengevaluasi keberhasilan deteksi wajah dan tidak dapat ditafsirkan sebagai ukuran akurasi sistem face matching.

E. Uji Ketahanan dan Keterbatasan

5.1 Analisis Sensitivitas

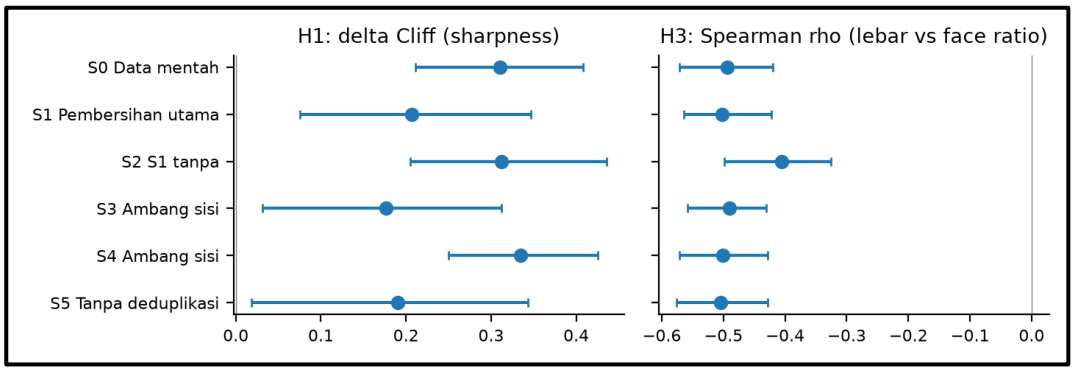
Analisis sensitivitas dilakukan untuk mengevaluasi perubahan hasil analisis statistik ketika diterapkan konfigurasi preprocessing yang berbeda pada dataset Indonesian Multi-Source Face Dataset (IMSFD). Analisis ini bertujuan mengetahui apakah arah dan besarnya hubungan statistik tetap konsisten ketika data mentah dibandingkan dengan data yang telah melalui pembersihan, perubahan ambang resolusi, dan penanganan duplikasi. Pengujian dilakukan melalui enam skenario, yaitu S0 (data mentah), S1 (pembersihan utama), S2 (pembersihan utama tanpa salah satu tahap yang ditentukan), S3 (ambang sisi terpendek 32 piksel), S4 (ambang sisi terpendek 128 piksel), dan S5 (tanpa deduplikasi). Definisi setiap skenario harus mengikuti konfigurasi aktual pada kode analisis :

1. S0 (Data Mentah): Menggunakan dataset awal sebelum dilakukan pembersihan sebagai kondisi dasar (baseline) untuk membandingkan hasil analisis dengan skenario lainnya.
2. S1 (Pembersihan Utama): Menggunakan dataset yang telah melalui tahapan pembersihan utama, meliputi penghapusan citra hitam, penyaringan citra berdasarkan ambang resolusi, dan deduplikasi.
3. S2 (S1 Tanpa Salah Satu Tahap Pembersihan): Menggunakan dataset hasil pembersihan utama dengan menghilangkan salah satu tahap preprocessing untuk mengetahui pengaruh tahap tersebut terhadap hasil analisis.

4. S3 dan S4 (Perubahan Ambang Sisi Minimum Citra): Menggunakan variasi ambang resolusi minimum untuk mengevaluasi pengaruh kriteria ukuran citra terhadap hasil analisis statistik.
5. S5 (Tanpa Deduplikasi): Menggunakan dataset tanpa penghapusan duplikasi untuk mengetahui apakah keberadaan citra duplikat memengaruhi estimasi statistik.

Perbandingan dilakukan menggunakan Cliff's delta pada Hipotesis 1 untuk mengevaluasi perbedaan distribusi sharpness antara citra yang berhasil dan tidak berhasil dideteksi. Pada Hipotesis 3, korelasi Spearman digunakan untuk mengevaluasi hubungan monoton antara lebar citra dan rasio area wajah.

Setiap skenario dibandingkan berdasarkan ukuran statistik yang relevan dengan hipotesis penelitian. Pada Hipotesis 1, ukuran efek Cliff's delta digunakan untuk mengevaluasi perbedaan distribusi sharpness antara citra yang berhasil dideteksi dan citra yang tidak berhasil dideteksi. Pada Hipotesis 3, korelasi peringkat Spearman digunakan untuk mengevaluasi hubungan monoton antara lebar citra dan rasio area wajah. Kedua ukuran tersebut diamati untuk mengetahui perubahan arah dan besarnya estimasi setelah penerapan konfigurasi preprocessing yang berbeda.



Gambar 5. 1 Perbandingan Ukuran Efek Cliff's Delta dan Korelasi Spearman pada Berbagai Skenario Analisis Sensitivitas.

Berdasarkan Gambar 5.1, estimasi Cliff's delta pada H1 menunjukkan variasi antar-skenario. Nilai estimasi yang terbaca pada grafik berada di sekitar 0,31 pada S0, 0,21 pada S1, 0,31 pada S2, 0,18 pada S3, 0,33 pada S4, dan 0,19 pada S5. Seluruh estimasi yang ditampilkan bernilai positif. Dengan asumsi urutan kelompok dalam perhitungan konsisten, arah perbedaan sharpness tetap sama pada seluruh skenario. Namun, perubahan besar estimasi menunjukkan bahwa besarnya perbedaan yang teramati dipengaruhi oleh konfigurasi preprocessing.

Pada H3, koefisien Spearman yang terbaca pada grafik berada di sekitar −0,50 pada S0, −0,50 pada S1, −0,40 pada S2, −0,49 pada S3, −0,50 pada S4, dan −0,50 pada S5. Seluruh estimasi bernilai negatif sehingga arah hubungan monoton antara lebar citra dan rasio area wajah tetap negatif pada skenario yang ditampilkan. Korelasi pada S2 terlihat lebih lemah dibandingkan sebagian besar skenario lainnya.

Secara deskriptif, hasil tersebut menunjukkan bahwa estimasi Cliff's delta mengalami variasi lebih besar daripada koefisien Spearman. Dengan demikian, besarnya perbedaan sharpness antara kelompok deteksi tampak lebih sensitif terhadap perubahan preprocessing, sedangkan arah hubungan antara lebar citra dan rasio area wajah cenderung bertahan. Meskipun demikian, kestabilan arah estimasi tidak membuktikan bahwa seluruh hasil signifikan secara statistik atau bahwa besarnya estimasi antarskenario tidak berbeda. Kesimpulan akhir perlu mempertimbangkan jumlah observasi, konsistensi definisi skenario, interval kepercayaan apabila dihitung, dan hasil pengujian statistik yang dapat diverifikasi dari kode. Dengan demikian, analisis sensitivitas memberikan bukti deskriptif mengenai perubahan estimasi akibat variasi preprocessing. Hasil ini dapat digunakan sebagai dasar untuk meninjau keputusan pembersihan dataset sebelum eksperimen lanjutan. Namun, ketahanan statistik hasil penelitian belum dapat dipastikan hanya berdasarkan grafik tersebut.

5.2 Keputusan Yang Paling Diragukan

Keputusan yang paling perlu dievaluasi adalah ambang penghapusan citra berdasarkan brightness dan resolusi. Adapun keputusan-keputusan yang perlu di evaluasi sebagai berikut :

- Penggunaan Ambang Brightness Di Bawah 5 Untuk Mengidentifikasi Kandidat Citra Hitam Serta Ambang Sisi Terpendek 64 Piksel Untuk Menyaring Citra Beresolusi Rendah. Kedua Ambang Tersebut Merupakan Kriteria Heuristik Yang Belum Tentu Optimal Untuk Seluruh Citra Dalam Dataset Imsfd.
- Citra Dengan Brightness Sangat Rendah Belum Tentu Tidak Memiliki Informasi Wajah, Sedangkan Citra Beresolusi Rendah Masih Dapat Mengandung Informasi Yang Berguna Untuk Metode Deteksi Tertentu. Oleh Karena Itu, Penghapusan Citra Perlu Didasarkan Pada Pemeriksaan Visual Dan Hasil Eksperimen, Bukan Hanya Satu Parameter.
- Perbandingan Ambang Resolusi 32, 64, Dan 128 Piksel Serta Analisis Sensitivitas Terhadap Penanganan Citra Tidak Valid Dapat Digunakan Untuk Mengevaluasi Perubahan Jumlah Data, Tingkat Deteksi, Dan Ukuran Statistik. Konfigurasi Akhir Sebaiknya Dipilih Berdasarkan Keseimbangan Antara Kualitas Data Dan Jumlah Citra Yang Dapat dipertahankan.

5.3 Keterbatasan Dataset dan Metode

5.3.1. Jumlah Identitas

Dataset memiliki 26.760 citra, tetapi hanya terdiri atas 68 identitas. Citra dari orang yang sama dapat memiliki karakteristik yang saling berkaitan sehingga tidak seluruh citra dapat dianggap sebagai observasi independen. Kondisi tersebut perlu diperhitungkan dalam analisis statistik dan perancangan pembagian data.

5.3.2. Variasi Kualitas Citra

Resolusi, pencahayaan, kontras, dan ketajaman citra menunjukkan variasi yang besar. Variasi tersebut dapat memengaruhi keberhasilan deteksi wajah dan kualitas representasi fitur yang dihasilkan model. Namun, indikator kualitas berbasis citra tidak secara langsung menggambarkan akurasi verifikasi identitas. Hubungan tersebut perlu diuji melalui eksperimen face matching.

5.3.3. Keterbatasan Haar Cascade

Haar Cascade dapat gagal mendeteksi wajah pada kondisi pose tertentu, pencahayaan rendah, oklusi, atau resolusi kecil. Oleh karena itu, status deteksi hanya menunjukkan keluaran algoritma, bukan kebenaran mutlak mengenai keberadaan wajah. Penggunaan detektor alternatif dan pemeriksaan visual dapat membantu menilai apakah kegagalan tersebut berasal dari karakteristik citra atau keterbatasan metode.

5.3.4. Resiko Duplikasi dan Kebocoran Data

Kemunculan citra identik atau hampir identik pada data pelatihan dan pengujian dapat membuat evaluasi model terlalu optimistis. Pemeriksaan berdasarkan metadata saja belum cukup untuk memastikan bahwa seluruh duplikasi telah ditemukan. Hash citra, perceptual hash, dan pemeriksaan visual diperlukan sebelum hasil evaluasi model digunakan untuk menarik kesimpulan.

5.3.5. Keterbatasan Generalisasi

Dataset yang digunakan memiliki jumlah identitas terbatas dan berasal dari sumber tertentu. Karakteristiknya belum tentu mewakili seluruh kondisi penggunaan sistem verifikasi identitas pada lingkungan nyata. Pengujian pada sumber citra, perangkat, pencahayaan, dan kondisi pengambilan yang berbeda diperlukan untuk mengevaluasi generalisasi.

5.3.6. Keterbatasan Evaluasi Face Matching

Notebook EDA yang tersedia belum melakukan ekstraksi embedding atau pengujian pasangan genuine dan impostor. Oleh sebab itu, belum terdapat bukti mengenai FAR, FRR, EER, TAR pada FAR tertentu, atau akurasi verifikasi identitas. Keterbatasan ini harus dinyatakan secara terbuka. Hasil EDA digunakan untuk mempersiapkan data dan merancang eksperimen, bukan sebagai bukti final bahwa sistem face matching telah bekerja dengan baik.

5.4 Perbandingan Dengan Penelitian Terdahulu

Temuan EDA ini berkaitan dengan beberapa bidang penelitian terdahulu.

- Viola dan Jones (2001) memperkenalkan metode deteksi objek berbasis boosted cascade yang menjadi dasar pendekatan Haar Cascade. Metode ini relevan untuk memahami bahwa keberhasilan deteksi dipengaruhi oleh karakteristik visual objek dan kondisi citra.
- Zhang et al. (2016) memperkenalkan MTCNN untuk deteksi dan alignment wajah. Pendekatan tersebut dapat menjadi pembanding bagi Haar Cascade pada tahap pengembangan sistem.
- Schlett et al. (2022) membahas penilaian kualitas citra wajah dan menunjukkan pentingnya kualitas masukan dalam sistem pengenalan wajah. Temuan ini relevan dengan variasi resolusi, brightness, contrast, dan sharpness yang ditemukan dalam EDA.
- Schroff et al. (2015) melalui FaceNet dan Deng et al. (2019) melalui ArcFace menjadi referensi bagi pengembangan representasi embedding untuk pengenalan wajah. Namun, kinerja model tersebut pada dataset IMSFD belum dapat disimpulkan dari EDA ini.
- Kaufman et al. (2012) membahas kebocoran data dalam data mining. Hal tersebut relevan dengan perlunya pemeriksaan duplikasi dan pembagian data yang sesuai sebelum evaluasi model.

Dengan demikian, perbandingan ini digunakan untuk memberikan dasar konseptual bagi preprocessing dan evaluasi lanjutan. Perbandingan tersebut bukan klaim bahwa metode-metode tersebut telah diuji langsung pada dataset IMSFD dalam pekerjaan ini.

F. Analisis dan Kesimpulan

6.1 Analisis Keseluruhan

Dataset IMSFD terdiri atas 26.760 citra dari 68 identitas yang terbagi dalam tiga subset, yaitu A1, A2, dan B1. Hasil EDA menunjukkan adanya variasi resolusi, brightness, contrast, sharpness, dan rasio area wajah. Selain itu, ditemukan citra yang tidak berhasil dideteksi, kandidat citra tidak valid, serta indikasi duplikasi yang memerlukan pemeriksaan lanjutan.

Berdasarkan tabel pembersihan, konfigurasi preprocessing utama menghasilkan 24.608 citra dari 26.760 citra awal. Hasil tersebut menunjukkan bahwa proses pembersihan mengurangi jumlah data yang digunakan dalam analisis. Namun, perubahan jumlah data tidak dengan sendirinya membuktikan bahwa kualitas seluruh citra meningkat.

Analisis lanjutan dirancang untuk menguji hubungan sharpness dengan keberhasilan deteksi wajah, perbedaan tingkat deteksi antar-subset, serta hubungan lebar citra dengan rasio area wajah. Analisis sensitivitas juga digunakan untuk mengevaluasi perubahan estimasi statistik ketika konfigurasi preprocessing diubah.

Temuan mengenai duplikasi dan keberadaan identitas yang sama pada kelompok pelatihan dan pengujian menunjukkan perlunya pemeriksaan kebocoran data. Oleh karena itu, hasil EDA harus digunakan sebagai dasar untuk memperbaiki persiapan data dan merancang eksperimen lanjutan, bukan sebagai bukti langsung mengenai akurasi sistem face matching..

6.2 Kesimpulan

Berdasarkan hasil EDA dan analisis yang dilakukan, diperoleh beberapa kesimpulan sebagai berikut.

1. Dataset IMSFD terdiri atas 26.760 citra dari 68 identitas dan memerlukan pemeriksaan kualitas sebelum digunakan dalam pemodelan.
2. Proses pembersihan utama dilaporkan menghasilkan 24.608 citra setelah penghapusan citra hitam, penyaringan berdasarkan resolusi, dan deduplikasi. Jumlah tersebut perlu dipastikan konsisten dengan keluaran program yang digunakan untuk menghasilkan grafik dan analisis statistik.
3. Tingkat keberhasilan deteksi wajah menunjukkan variasi antar-kategori resolusi. Temuan ini memberikan indikasi bahwa resolusi perlu dipertimbangkan dalam preprocessing, tetapi tidak membuktikan hubungan sebab-akibat.
4. Perbandingan sharpness antara citra yang berhasil dan tidak berhasil dideteksi perlu dievaluasi menggunakan ukuran efek dan pengujian statistik yang sesuai. Kesimpulan signifikansi harus didasarkan pada keluaran uji yang dapat diverifikasi.
5. Perbedaan tingkat deteksi antar-subset dan hubungan antara lebar citra dengan rasio area wajah perlu ditafsirkan dengan mempertimbangkan karakteristik dataset, jumlah observasi, dan ketergantungan antarcitra.
6. Analisis sensitivitas menunjukkan perubahan estimasi statistik pada berbagai konfigurasi preprocessing. Namun, ketahanan statistik hasil penelitian belum dapat dipastikan hanya berdasarkan perubahan arah dan besarnya estimasi pada grafik.
7. Pemeriksaan duplikasi dan pembagian data yang sesuai merupakan langkah penting sebelum mengevaluasi model pengenalan wajah.

Secara keseluruhan, EDA memberikan dasar untuk mempersiapkan dataset dan merancang eksperimen face matching. Penelitian selanjutnya perlu melengkapi pengujian statistik, memastikan tidak terjadi kebocoran

data, dan mengevaluasi sistem menggunakan metrik verifikasi identitas yang sesuai.

6.3 Implikasi Terhadap Rencana Tesis

Hasil EDA menjadi dasar untuk mempersiapkan dataset dalam pengembangan sistem face matching berbasis deep face recognition. Tahap berikutnya meliputi pemeriksaan kualitas citra, deteksi dan alignment wajah, cropping, resizing, serta ekstraksi embedding menggunakan model pengenalan wajah yang sesuai.

Evaluasi sistem akan menggunakan pasangan genuine dan impostor dengan pembagian data yang dirancang untuk mencegah kebocoran data. Metrik evaluasi dapat mencakup False Acceptance Rate (FAR), False Rejection Rate (FRR), Equal Error Rate (EER), dan True Acceptance Rate (TAR) pada tingkat FAR tertentu.

Selain itu, penelitian selanjutnya dapat mengevaluasi pengaruh resolusi, pencahayaan, dan ketajaman citra terhadap kualitas embedding dan kinerja verifikasi identitas. Seluruh pendekatan tersebut perlu diuji melalui eksperimen sehingga hasil EDA tidak langsung dianggap sebagai bukti keberhasilan sistem face matching..

6.4 Reproduksibilitas Kode dan Pelaporan Eksperimen

Kode analisis disiapkan untuk mendukung reproduksibilitas proses EDA, preprocessing, pengujian hipotesis, dan analisis sensitivitas pada dataset IMSFD. Struktur program mencakup pemuatan data, pemeriksaan metadata, identifikasi citra tidak valid, evaluasi resolusi, pemeriksaan duplikasi, visualisasi distribusi, pengujian statistik, dan penyimpanan hasil analisis.

Dokumentasi README menjelaskan kebutuhan lingkungan, pustaka yang digunakan, struktur folder, parameter preprocessing, urutan eksekusi, dan keluaran program. Setiap skenario analisis sensitivitas perlu

mencatat konfigurasi yang digunakan serta jumlah observasi dan ukuran statistik yang dihasilkan.

- Tautan kode :
  a) Google Collab [https://colab.research.google.com/drive/1S0A1_n-2ReTjONsdc0L0nQ2kpheGhe39?usp=sharing]
  b) Link Github [https://github.com/raihanrid/EDA_RaihanRidho_IMSFD]

Dokumentasi ini digunakan untuk membantu pemeriksaan ulang hasil penelitian dan memastikan bahwa kesimpulan didasarkan pada keluaran program yang dapat ditelusuri.

6.5 Kesimpulan Akhir

Tindak lanjut EDA terhadap dataset IMSFD menunjukkan bahwa kualitas dan validitas data merupakan fondasi penting dalam pengembangan sistem pengenalan wajah. Citra yang tidak valid, resolusi yang terlalu kecil, duplikasi, dan kegagalan deteksi perlu ditangani sebelum ekstraksi embedding dilakukan. Pengujian hipotesis juga menunjukkan bahwa kualitas citra berhubungan dengan keberhasilan deteksi, tetapi hasilnya masih dipengaruhi oleh karakteristik dataset dan keputusan preprocessing.

Oleh karena itu, penelitian selanjutnya perlu memprioritaskan pipeline preprocessing yang konsisten, pembagian data bebas kebocoran, pengujian model embedding, serta evaluasi verifikasi identitas menggunakan metrik yang sesuai. Hasil EDA ini menjadi dasar bagi eksperimen yang lebih terukur dan dapat direproduksi untuk mendukung pengembangan sistem face matching berbasis Deep Face Recognition.

DAFTAR PUSTAKA

Deng, J., Guo, J., Xue, N., & Zafeiriou, S. (2019). ArcFace: Additive angular margin loss for deep face recognition. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).

Grother, P., Ngan, M., & Hanaoka, K. (2019). Face Recognition Vendor Test (FRVT) Part 3: Demographic Effects. NISTIR 8280. National Institute of Standards and Technology.

Huang, G. B., Ramesh, M., Berg, T., & Learned-Miller, E. (2007). Labeled Faces in the Wild: A Database for Studying Face Recognition in Unconstrained Environments. Technical Report 07-49, University of Massachusetts Amherst.

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. Patterns, 4(9).

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. ACM Transactions on Knowledge Discovery from Data, 6(4).

Pech-Pacheco, J. L., Cristóbal, G., Chamorro-Martínez, J., & Fernández-Valdivia, J. (2000). Diatom autofocusing in brightfield microscopy: A comparative study. Proceedings of the 15th International Conference on Pattern Recognition (ICPR).

Schlett, T., Rathgeb, C., Henniger, O., Galbally, J., Fierrez, J., & Busch, C. (2022). Face image quality assessment: A literature survey. ACM Computing Surveys, 54(10s).

Schroff, F., Kalenichenko, D., & Philbin, J. (2015). FaceNet: A unified embedding for face recognition and clustering. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

Viola, P., & Jones, M. (2001). Rapid object detection using a boosted cascade of simple features. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

Wang, Z., Wang, Z., Chang, S., et al. (2014). Low-resolution face recognition: A review. The Visual Computer, 30.

Zhang, K., Zhang, Z., Li, Z., & Qiao, Y. (2016). Joint face detection and alignment using multitask cascaded convolutional networks. IEEE Signal Processing Letters, 23(10).